

作者	生姜 DrGinger
脚本	生姜 DrGinger
视频	崔崔 CuiCui
开源学习资源	https://github.com/Visualize-ML
平台	https://www.youtube.com/@DrGinger_Jiang https://space.bilibili.com/3546865719052873 https://space.bilibili.com/513194466

12.2 椭圆视角看主成分分析



本节你将掌握的核心技能：

- ▶ 用椭圆或椭球来几何直观地描述数据分布。
- ▶ 对每列数据去均值，使质心移动到原点。
- ▶ 协方差矩阵描述数据结构。
- ▶ 谱分解提取数据的主轴方向及方差。
- ▶ 方阵的迹是主对角线上所有元素的总和。
- ▶ 将数据投影到特征向量方向，实现信息压缩。
- ▶ 通过旋转坐标轴（主成分方向）“摆正”数据形状。

把数据矩阵想象成一朵云，而描述这朵云的合适的几何形状可以是椭圆、椭球。主成分分析就是找到合适的坐标系把代表数据的椭圆、椭球摆正；然后在新的坐标系中完成投影。

⚠ 注意，使用主成分分析时，我们假设数据服从多元高斯分布。“数学不难”系列的《概率统计不难》将会专门讲解多元高斯分布。

我们能不能找到一个新的坐标轴，使得数据变得“摆正”？并且“压平”在最有用的方向上。这就是主成分分析的几何直觉。

我们用数据矩阵计算协方差矩阵；用协方差矩阵描述椭圆、椭球。用特征值分解（谱分解）找到椭圆、椭球的主轴（主元方向）。用正交投影将数据降维到主元方向。从这个思路来看，我们将会用到本书前文介绍的谱分解、正交投影、格拉姆矩阵等工具。

主成分分析步骤

主成分分析的步骤如下：

- ▶ 数据矩阵列中心化（标准化，如果不同特征上方差差异过大）；

本 PDF 文件为作者草稿，发布目的为方便读者在移动终端学习，终稿内容以清华大学出版社纸质出版物为准。

版权归清华大学出版社所有，请勿商用，引用请注明出处。

代码及 PDF 文件下载：<https://github.com/Visualize-ML>

本书配套微课视频均发布在 B 站——生姜 DrGinger：<https://space.bilibili.com/513194466>

欢迎大家批评指教，本书专属邮箱：jiang.visualize.ml@gmail.com

- ▶ 计算协方差矩阵；
- ▶ 对协方差矩阵特征值分解；
- ▶ 按特征值从大到小顺序排列对应特征向量；
- ▶ 选出主元方向（最大特征值对应的向量）；
- ▶ 将数据矩阵投影到主元方向。

⚠ 注意，计算协方差矩阵时，数据中心化（多数情况下）已经包含在内。

下面让我们逐步来看主成分分析。

数据矩阵

假设我们有一组二维数据点，对应的数据矩阵为

$$\mathbf{X}_{300 \times 2} = \begin{bmatrix} 2.272 & 1.672 \\ 2.031 & 3.272 \\ \vdots & \vdots \\ 4.894 & 3.716 \end{bmatrix} \quad (1)$$

数据矩阵有 300 行，即 300 个样本点。

如图 1 所示，数据散点像一团斜着的椭圆云。



图 1 中椭圆实际上是马氏距离等高线，马氏距离是本书第 13 章、第 4 节要介绍的话题。




图 1. 旋转椭圆“数据云”

如图 2 所示，数据的质心就是旋转椭圆的中心，通过如下矩阵乘法，我们计算得到了质心具体位置

$$\boldsymbol{\mu} = \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} = \frac{\mathbf{X}^T \mathbf{I}}{n} = \frac{1}{300} \times \begin{bmatrix} 2.272 & 1.672 \\ 2.031 & 3.272 \\ \vdots & \vdots \\ 4.894 & 3.716 \end{bmatrix}^T @ \begin{bmatrix} 1 \\ 1 \\ 1 \\ 1 \end{bmatrix} = \begin{bmatrix} 4 \\ 3 \end{bmatrix} \quad (2)$$




图 2. “数据云”的质心

如图 3 所示，数据矩阵 \mathbf{X} 向横轴投影得到 \mathbf{x}_1 ，即

$$\mathbf{X} @ \begin{bmatrix} 1 \\ 0 \end{bmatrix} = [\mathbf{x}_1 \quad \mathbf{x}_2] @ \begin{bmatrix} 1 \\ 0 \end{bmatrix} = \mathbf{x}_1 \quad (3)$$

质心 $\boldsymbol{\mu}$ 向 x_1 轴投影，便得到 μ_1

$$\mu_1 = \boldsymbol{\mu}^T \mathbf{e}_1 = \mathbf{e}_1^T \boldsymbol{\mu} = [1 \quad 0] @ \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} \quad (4)$$

上式本质上是标量投影。




图 3. 数据矩阵向横轴投影

类似地，如图 4 所示，数据矩阵 \mathbf{X} 向纵轴投影得到 \mathbf{x}_2 ，即

$$\mathbf{X} @ \begin{bmatrix} 0 \\ 1 \end{bmatrix} = [\mathbf{x}_1 \quad \mathbf{x}_2] @ \begin{bmatrix} 0 \\ 1 \end{bmatrix} = \mathbf{x}_2 \quad (5)$$

质心 $\boldsymbol{\mu}$ 向 x_2 轴投影，便得到 μ_2

$$\mu_2 = \boldsymbol{\mu}^T \mathbf{e}_2 = \mathbf{e}_2^T \boldsymbol{\mu} = [0 \quad 1] @ \begin{bmatrix} \mu_1 \\ \mu_2 \end{bmatrix} \quad (6)$$




图 4. 数据矩阵向纵轴投影

数据中心化

上一节提过，数据中心化（去均值）是指数据矩阵 X 每列减去其所在列的均值得到 X_c 。用广播原则

$$X_c = X - \mu^T \quad (7)$$

如图 5 所示，数据（列）中心化没有改变数据的分布形状，但会将数据中心平移到原点（零向量 $\mathbf{0}$ ）。




图 5. 数据中心化

协方差矩阵

使用中心化后的数据，计算特征之间的协方差矩阵，表示各变量之间的线性相关性。

上一节提到，协方差矩阵相当于中心化数据矩阵的一种格拉姆矩阵，即

$$\Sigma = \frac{\mathbf{X}_c^T \mathbf{X}_c}{n-1} \quad (8)$$

带入具体值，我们得到图 1 数据的协方差矩阵

$$\Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix} \quad (9)$$

协方差矩阵主对角线为方差，也就是说图 3、图 4 不同轴投影数据的方差都是 1。开平方得到标准差，也都是 1。协方差矩阵非主对角线元素为协方差，这意味着 \mathbf{x}_1 、 \mathbf{x}_2 的协方差为 0.5。

\mathbf{x}_1 、 \mathbf{x}_2 的线性相关性系数也是 0.5，即

$$\rho_{1,2} = \frac{\text{cov}(\mathbf{x}_1, \mathbf{x}_2)}{\sigma_1 \sigma_2} = \frac{0.5}{1 \times 1} = 0.5 \quad (10)$$

⚠ 注意，由于图 1 数据方差（标准差）相差不大，直接对协方差矩阵进行特征值分解完成主成分分析即可；但是，如果方差相差很大，需要先对数据标准化，这是下一节要介绍的话题。

特征值分解

对 (9) 协方差矩阵进行特征值分解

$$\Sigma = \begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix} = \underbrace{\begin{bmatrix} \sqrt{2}/2 & -\sqrt{2}/2 \\ \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}}_{\mathbf{V}} \underbrace{\begin{bmatrix} 1.5 & 0 \\ 0 & 0.5 \end{bmatrix}}_{\mathbf{\Lambda}} \underbrace{\begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 \\ -\sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix}}_{\mathbf{V}^T} = \mathbf{V}\mathbf{\Lambda}\mathbf{V}^T \quad (11)$$

上式中 \mathbf{V} 和 $\mathbf{\Lambda}$ 到底有怎样的含义？

让我们还是用几何视角分析。

如图 6 所示，中心化数据朝 \mathbf{v} 方向投影，得到的投影数据 \mathbf{y} 为

$$\mathbf{y} = \mathbf{X}_c \mathbf{v} \quad (12)$$

由于 \mathbf{X}_c 的质心位于原点， \mathbf{y} 的均值为 0。




图 6. 中心化数据投影

计算投影数据 \mathbf{y} 的方差

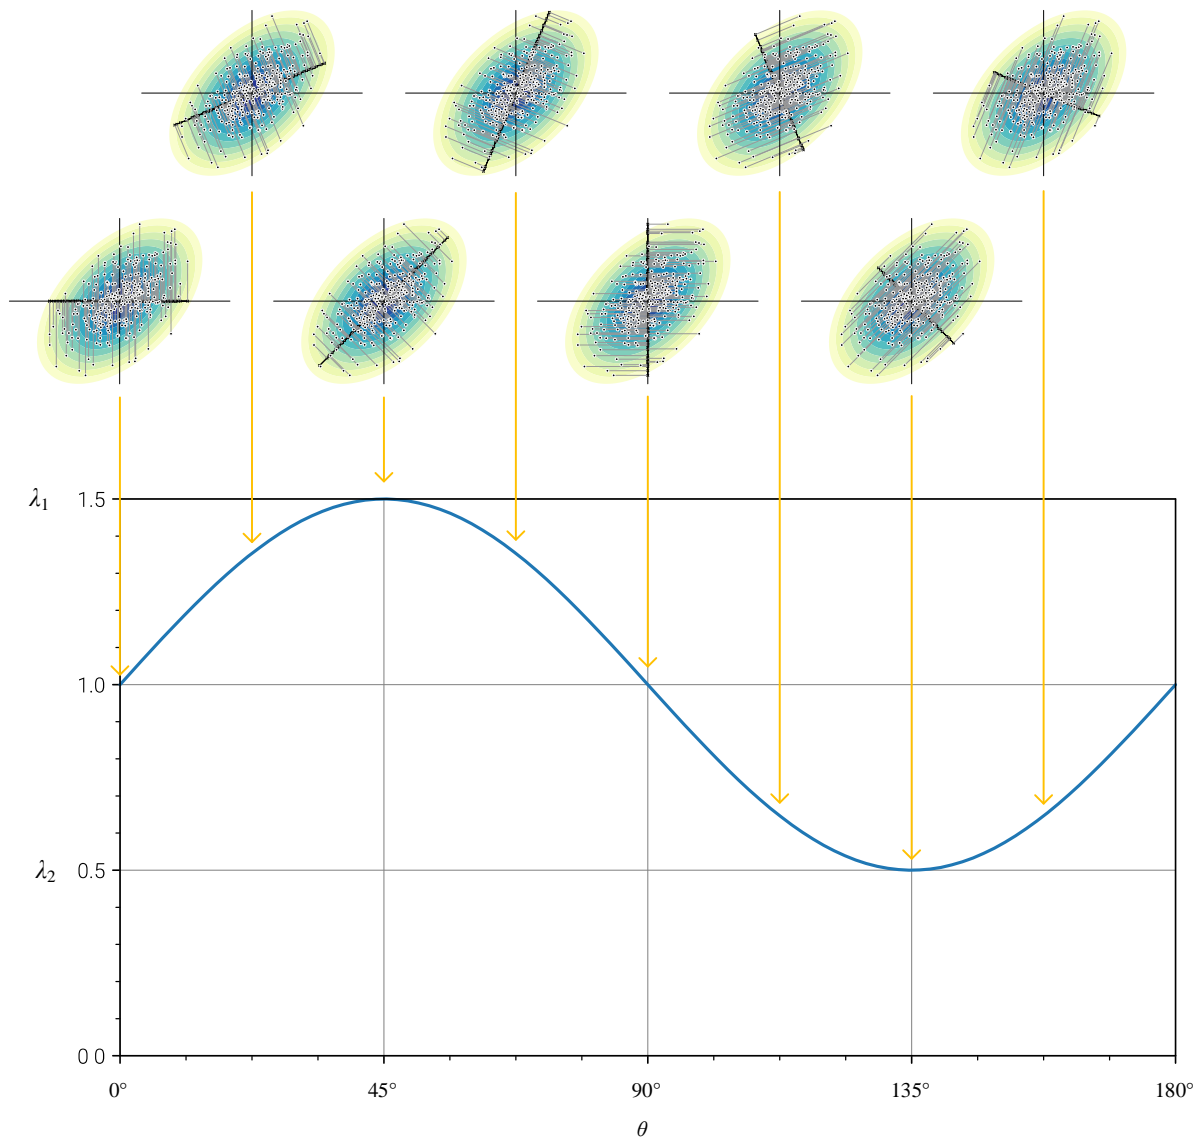
$$\text{var}(\mathbf{y}) = \frac{\mathbf{y}^T \mathbf{y}}{n-1} = \frac{(\mathbf{X}_c \mathbf{v})^T \mathbf{X}_c \mathbf{v}}{n-1} = \mathbf{v}^T \frac{\mathbf{X}_c^T \mathbf{X}_c}{n-1} \mathbf{v} = \mathbf{v}^T \Sigma \mathbf{v} \quad (13)$$

向量 \mathbf{v} 和横轴正方向的夹角为 θ 。

图 7 所示为方差随 θ 变化，而上式的最大值对应协方差矩阵 Σ 的最大特征值 (1.5)，最小值为最小特征值 (0.5)。



(13) 是特殊的瑞利商。此外，大家是否发现图 7 为三角函数？！这些都是本书第 13 章、第 3 节要讨论的话题。

图 7. 方差随 θ 变化

而 V 的两个特征向量就是最大、最小特征值对应的方向，

$$V = [v_1 \ v_2] = \begin{bmatrix} \sqrt{2}/2 & -\sqrt{2}/2 \\ \sqrt{2}/2 & \sqrt{2}/2 \end{bmatrix} \quad (14)$$

v_1 、 v_2 和横轴正方向夹角分别为 35 度、135 度，对应图 7 最大值、最小值的角度值。

根据 (11)，协方差矩阵可以对角化

$$V^T \Sigma V = \Lambda \quad (15)$$

把 V 写成列向量 $[v_1 \ v_2]$ 展开上式得到

$$[v_1 \ v_2]^T \Sigma [v_1 \ v_2] = \begin{bmatrix} v_1^T \\ v_2^T \end{bmatrix} \Sigma \begin{bmatrix} v_1 \\ v_2 \end{bmatrix} = \begin{bmatrix} v_1^T \Sigma v_1 & v_1^T \Sigma v_2 \\ v_2^T \Sigma v_1 & v_2^T \Sigma v_2 \end{bmatrix} = \begin{bmatrix} \lambda_1 & 0 \\ 0 & \lambda_2 \end{bmatrix} \quad (16)$$

请大家格外注意如下两个等式，我们马上要用到

本 PDF 文件为作者草稿，发布目的为方便读者在移动终端学习，终稿内容以清华大学出版社纸质出版物为准。

版权归清华大学出版社所有，请勿商用，引用请注明出处。

代码及 PDF 文件下载：<https://github.com/Visualize-ML>

本书配套微视频均发布在 B 站——生姜 DrGinger：<https://space.bilibili.com/513194466>

欢迎大家批评指教，本书专属邮箱：jiang.visualize.ml@gmail.com

$$\begin{aligned} \mathbf{v}_1^T \Sigma \mathbf{v}_1 &= \lambda_1 \\ \mathbf{v}_2^T \Sigma \mathbf{v}_2 &= \lambda_2 \end{aligned} \quad (17)$$

此外，还有一点值得大家注意，协方差的迹 (trace) 和特征值分解得到的 Λ 迹相同，即

$$\begin{aligned} \text{trace}(\Sigma) &= \text{trace}\left(\begin{bmatrix} 1 & 0.5 \\ 0.5 & 1 \end{bmatrix}\right) = 1 + 1 = 2 \\ \text{trace}(\Lambda) &= \text{trace}\left(\begin{bmatrix} 1.5 & 0 \\ 0 & 0.5 \end{bmatrix}\right) = 1.5 + 0.5 = 2 \end{aligned} \quad (18)$$

简单来说，一个方阵的迹等于它所有特征值 (包括重复) 的总和。

投影

特征值越大，说明该方向上数据的方差越大，信息越丰富。

如图 8 所示，中心化数据矩阵 \mathbf{X}_c 向 \mathbf{v}_1 投影数据为 \mathbf{y}_1

$$\mathbf{y}_1 = \mathbf{X}_c \mathbf{v}_1 \quad (19)$$

计算 \mathbf{y}_1 方差

$$\text{var}(\mathbf{y}_1) = \frac{\mathbf{y}_1^T \mathbf{y}_1}{n-1} = \frac{(\mathbf{X}_c \mathbf{v}_1)^T \mathbf{X}_c \mathbf{v}_1}{n-1} = \mathbf{v}_1^T \frac{\mathbf{X}_c^T \mathbf{X}_c}{n-1} \mathbf{v}_1 = \mathbf{v}_1^T \Sigma \mathbf{v}_1 = \lambda_1 \quad (20)$$

这意味着 \mathbf{y}_1 的方差为 1.5 (λ_1)。




图 8. 数据朝 \mathbf{v}_1 投影

类似地，如图 9 所示，中心化数据矩阵 \mathbf{X}_c 向 \mathbf{v}_2 投影数据为 \mathbf{y}_2

$$\mathbf{y}_2 = \mathbf{X}_c \mathbf{v}_2 \quad (21)$$

计算 \mathbf{y}_2 方差

$$\text{var}(\mathbf{y}_2) = \frac{\mathbf{y}_2^T \mathbf{y}_2}{n-1} = \frac{(\mathbf{X}_c \mathbf{v}_2)^T \mathbf{X}_c \mathbf{v}_2}{n-1} = \mathbf{v}_2^T \frac{\mathbf{X}_c^T \mathbf{X}_c}{n-1} \mathbf{v}_2 = \mathbf{v}_2^T \boldsymbol{\Sigma} \mathbf{v}_2 = \lambda_2 \quad (22)$$

这意味着 \mathbf{y}_2 的方差为 $0.5 (\lambda_2)$ 。

观察图 8、图 9，我们发现 \mathbf{v}_1 对应椭圆的长轴方向，也是第一主元的方向； \mathbf{v}_2 对应椭圆的短轴方向，也是第二主元的方向。

数据朝不同方向投影会得到不同的投影结果，对应不同的分布；朝椭圆长轴方向投影，得到的数据标准差最大；朝椭圆短轴方向投影得到的数据标准差最小。




图 9. 数据朝 \mathbf{v}_2 投影

在规范正交基 \mathbf{V} 中看数据

由于协方差矩阵为对称矩阵，因此特征值分解（谱分解）得到的 \mathbf{V} 为正交矩阵。 \mathbf{V} 的列向量构成规范正交基。

换个视角来看，如图 10 所示，主成分分析无非就是 \mathbf{V} 中看同一组数据。




图 10. 在 $[v_1, v_2]$ 中看中心化数据

图 11 所示为在 $[v_1, v_2]$ 中朝 v_1 投影结果。图 12 所示为在 $[v_1, v_2]$ 中朝 v_2 投影结果。

图 11. 在 $[v_1, v_2]$ 中看中心化数据，朝 v_1 投影

图 12. 在 $[v_1, v_2]$ 中看中心化数据，朝 v_2 投影

LA_12_02_01.ipynb 完成本节主要运算以及可视化，请大家自学。



请大家用 DeepSeek/ChatGPT 等工具完成本节如下习题。

- Q1.** 请大家了解马氏距离。
- Q2.** 请大家自学 LA_12_02_01.ipynb 中的 mahalanobis_distance() 这个计算马氏距离的函数。
- Q3.** 请大家将 LA_12_02_01.ipynb 可视化函数写成一个自定义函数，方便反复调用。